

Provjera dostupnosti proizvoda na dućanskim policama

Uvod

Sve veća potreba za provjerom dostupnosti proizvoda na dućanskim policama dovodi nas do problema automatizacije procesa. Proizvođačima je cilj da njihovi proizvodi budu na policama na mjestu koje oni plaćaju kako bi više potrošača dolazilo u doticaj s njihovim proizvodima. Tu dolazimo do potrebe za korištenje tehnika strojnog učenja u svrhu provjere dostupnosti proizvoda na policama. Potreba za automatizacijom i korištenjem tehnika računalnog vida dolazi jer ne postoji sustav koji bi pratio količinu i mjesto na kojem se nalazi proizvod tzv. dostupnost na polici (on-shelf availability) (OSA) te se to mora raditi ručno a to je dugotrajan i monoton posao.

Ovaj seminarski rad će se fokusirati na detekciju praznina na policama kao jedan od koraka boljeg razumijevanja korištenja računalnog vida u svrhu detekcije proizvoda i analize dostupnosti i položaja na policama.

Duboko učenje i YOLOv5

Jedan od glavnih zadataka računalnog vida je detekcija objekata zajedno s njihovim lokacijama i klasama (kao što su automobili, voće, prehrambeni proizvodi) na slikama. Metode otkrivanja objekata mogu se grupirati u dvije kategorije: tradicionalne metode obrade slike i metode detekcije temeljene na dubokom učenju. Nedavno su metode otkrivanja objekata temeljene na dubokom učenju postale popularne zbog izvanrednih rezultata. Detekcija i prepoznavanje objekata se smatra jednostavnim zadatkom za ljudski mozak, iako nije tako trivijalan za računala. Identifikacija i lokalizacija objekata na fotografijama je dio računalnog vida koji se naziva „detekcija objekata“. Nekoliko algoritama se pojavilo u posljednjih nekoliko godina za rješavanje problema detekcije objekata. Jedan od najpopularnijih algoritama za detekciju u stvarnom vremenu je YOLO (You Only Look Once). YOLO algoritam je do sada imao 5 verzija počevši od 2015. kad je objavljen YOLOv1. U godinama između došlo je do velikog razvoja algoritma te je trenutno najnoviji algoritam YOLOv5 koji nudi odlične performanse i jednostavno korištenje.

Implementacija

Kao što je bilo riječi u uvodu, u ovom radu je bilo potrebno iskoristiti YOLOv5 za detekciju praznina na policama. Za izvršavanje ovog zadatak koristio se Google Colab zajedno s Google Drive-om za spremanje slika i labela. Google Colab nudi pokretanje Python koda putem Jupyter bilježnica gdje se jednostavno dodaju potrebni moduli za potrebe ovog rada. Također unutar radnog okruženja je moguće koristiti odlične grafičke kartice za brže treniranje modela.

Rad je započeo pripremom podataka, podaci su se učitali na Drive odakle su se učitali u radnu bilježnicu, sljedeći korak je bio pretvorba labela. Bilo je potrebno filtrirati sve praznine koje se vide manje od 40% i ukloniti ih, također je bilo potrebno pretvoriti labela u format koji YOLOv5 prihvaća.

Svaka slika je imala svoju istoimenu JSON datoteku u kojoj su se sve praznine na toj slici s pripadnim koordinatama. Format kojeg YOLOv5 koristi izgleda ovako:

<broj klase, x_centar, y_centar, širina, visina>

Također podatke je potrebno normalizirati na raspon 0-1.

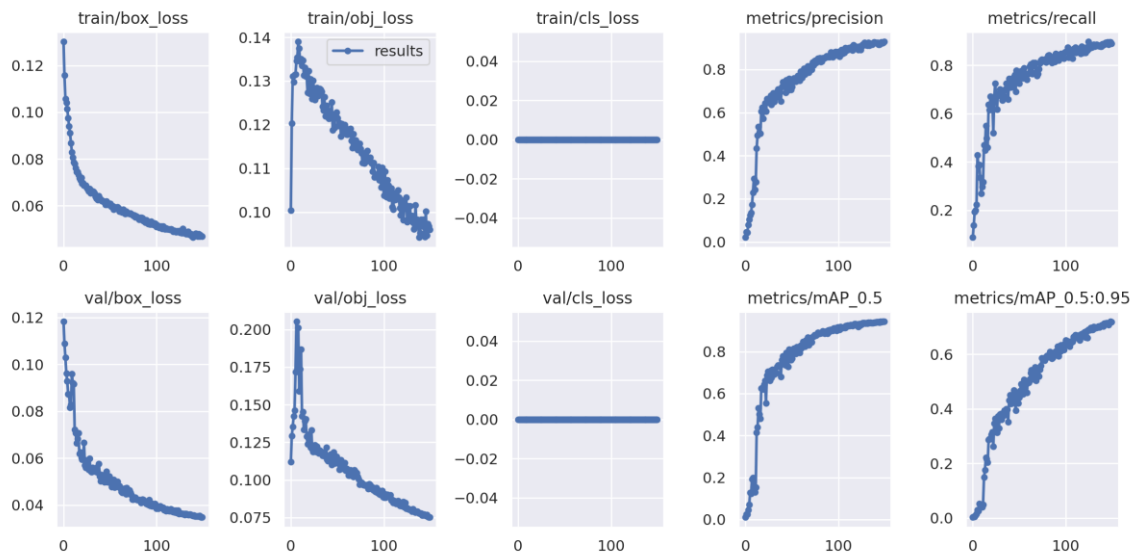
Nakon obrade podataka podaci su podijeljeni na skupa za učenje i skup za testiranje u omjeru 80:20. Cijeli podatkovni skup je sadržavao 1000 slika.

Učenje YOLOv5 modela je vrlo jednostavno, potrebno je postaviti put do yaml datoteke koja sadržava putanje do direktorija sa slikama, broj epoha koji je u ovom radu postavljen na 150, veličinu grupa za učenje (*batch size*), veličinu slike koju želimo koristiti te želimo li koristiti slučajne vrijednosti težina ili pretrenirane koje YOLO nudi i preporuča kako bi se ubrzao proces učenja. Uz ove parametre korišteni su još i stopa učenja 0.01 te je korišten stohastički gradijenti spust za optimizator.

Nakon završenog učenja, provedeno je testiranje na skupu za testiranje s najboljim iznosima težina koje su dobivene tijekom treniranja i detekcija praznina koja nam služi da dobijemo vizualni prikaz gdje se praznine nalaze.

Rezultati

Konačni rezultati ovog rada su zadovoljavajući i pokazuju kako YOLOv5 nudi odlične rezultate uz jednostavno korištenje. Daljnjim istraživanjem i poboljšanjem ovog rada može se doći do još bolje točnosti i preciznosti na neviđenim podacima.



Na slici iznad vidimo sve metrike koje YOLOv5 prikazuje nakon izvođenja. Može se vidjeti da gubitci opadaju do vrlo malih razina što ukazuje da algoritam konvergira da rješenja. Također vidimo da metrike poput preciznost, odziva i srednja prosječna preciznost (mAP) rastu preko 80% što ukazuje na dobru detekciju praznina. „cls_loss“ označuje gubitak po klasi, i on se računa kao gubitak kros-entropije te je ta metrika uvijek 0 u našem slučaju jer radimo samo s jednom klasom.


Slika ispod prikazuje krivulju preciznosti i odziva. Krivulja preciznosti i odziva pokazuje kompromis između preciznosti i odziva za različite vrijednosti. Velika površina ispod krivulje predstavlja veliku preciznost i veliki odziv, pri čemu se velika preciznost odnosi na nisku stopu lažno pozitivnih, a veliki odziv na nisku lažno negativnu stopu.

Konačni postoci po metrikama na skupu za treniranje su:


Preciznost: 92.5%

Odziv: 89.6%

mAP: 94.3%



Na skupu za testiranje vidimo koliko dobro zapravo YOLOv5 radi. Na temelju rezultata može se zaključiti da algoritam ima dobru sposobnost generalizacije u detekciji svih vrsta praznina, pa se može učinkovito koristiti za njihovo dobro prepoznavanje.



Na slici iznad vidimo krivulju preciznost i odziva na skupu za testiranje. Kada se usporedi s istim grafom na skupu za testiranje vidimo da je površina ispod neznatno manja što nam ukazuje na dobru generalizaciju. Ovo je posljedica većeg broja lažno pozitivnih primjera kojih ima više na skupu za testiranje što je vidljivo na slikama niže.



Konačni postoci po metrikama na skupu za testiranje su:

Preciznost: 85.7%

Odziv: 81.3%

mAP: 87.6

Zaključak

U ovom radu su opisane potrebe ovog rada, što su i na koji način se koristi duboko učenje i YOLOv5 algoritam, na koji način je proveden rad te što je u njemu implementirano te na kraju se priča o postignutim rezultatima rada.

Kroz rad se vidi kako rješenje problema automatizacije provjere proizvoda na dućanskim policama nije trivijalan problem te se ističe potreba za korištenjem tehnika strojnog učenja u svrhu provjere polica. Tu dolazimo do potrebe računalnog vida kao jedne od grana dubokog učenja za ovakve probleme. Jedan od glavnih zadataka računalnog vida je detekcija objekata zajedno s njihovim lokacijama i klasama (kao što su automobili, voće, prehrambeni proizvodi) na slikama. YOLOv5 je algoritam upravo za to, taj algoritam je ujedno i jedan od najpopularnijih algoritama za detekciju objekata u stvarnom vremenu.

Konačni rezultati su zadovoljavajući i pokazuju samu moć YOLOv5 algoritma za detekciju objekata. Iz rezultata je vidljivo da je najveći problem nedovoljno velik broj slika za treniranje i mali broj epoha što rezultira većim brojem lažno pozitivnih primjera.